Текст выступления (не больше 7 минут)

Текст разбит по слайдам. Синие подсказки в квадратных скобках читать вслух не нужно.
Чистого текста — около 5 минут 40 секунд, вместе с демонстрацией — около 6 минут 30 секунд. Остаётся запас, чтобы говорить спокойно.
Если время поджимает, сократить слайд 8 до одной фразы: «Лучше всего искать по основам слов — так поиск находит ответ в 96% случаев».

Слайд 1. Название · 15 секунд

Здравствуйте, уважаемые члены жюри! Меня зовут [имя и фамилия], я учусь в 9 классе. Моя работа называется «Цифровой помощник по творчеству Расула Гамзатова: может ли нейросеть отвечать на вопросы без выдумок?».

Слайд 2. Проблема · 25 секунд

Многие школьники делают уроки с помощью нейросетей. Нейросеть всегда отвечает уверенно. Но правильно ли?

У нейросетей есть проблема — **галлюцинации**: нейросеть придумывает ответ, который звучит правдоподобно, но неверен. О Расуле Гамзатове в интернете написано намного меньше, чем о Пушкине, поэтому нейросеть знает о нём мало и ошибается чаще.

Слайд 3. Что отвечает нейросеть · 20 секунд

Я проверила это сама. На вопрос «Кто перевёл „Журавли“ на русский язык?» нейросеть уверенно ответила: Пушкин. Героиню «Горянки» она назвала Айгуль, а похороненным Гамзатова — в Казани. Все ответы звучат уверенно, и все неверные.

Слайд 4. Гипотеза и цель · 25 секунд

Моя **гипотеза**: без источников небольшая нейросеть плохо отвечает на вопросы о Гамзатове, а с библиотекой проверенных текстов доля верных ответов сильно вырастет.

Цель — проверить это. Задачи на слайде: разобраться, почему нейросети выдумывают, собрать библиотеку, написать помощника, сравнить способы поиска и сравнить ответы с библиотекой и без неё.

Слайд 5. Что такое RAG · 30 секунд

Мой помощник работает по подходу **RAG** — это **экзамен с открытой книгой**.

В нём два помощника. **Библиотекарь** находит три самых подходящих кусочка текста — я называю их карточками. **Рассказчик** — это нейросеть. Она получает задание: «Ответь, используя только эти фрагменты. Если ответа нет, так и скажи». Поэтому ей не нужно выдумывать, а пользователь видит, откуда взят ответ.

Слайд 6. Как я делала проект · 30 секунд

Работа шла в три шага.

Первый — сбор. Моя программа-парсер скачала 20 статей из Википедии и Викицитатника. У них свободная лицензия, поэтому тексты можно законно использовать.

Второй — нарезка. Программа разрезала тексты на 303 карточки. Каждая помнит, из какой статьи она взята.

Третий — помощник. Нейросеть Qwen занимает около 1 гигабайта и работает прямо на обычном ноутбуке, без интернета.

Слайд 7. Как я проверяла · 25 секунд

Я составила **50 вопросов**: **45 обычных** с правильными ответами и **5 ловушек**. Ловушка — это вопрос с подвохом, например: «За какой роман Гамзатов получил Нобелевскую премию?». Он её не получал, и верный ответ — «нет» или «не знаю». Поэтому ловушки я считала отдельно.

Ответ засчитывался как верный, если в нём есть ключевое слово, например «1923» или «Гребнев».

Слайд 8. Эксперимент 1: поиск · 25 секунд

Сначала я проверила библиотекаря и сравнила три способа поиска. Лучше всего сработал поиск по **основам слов**: среди пяти карточек он находит ответ для **96% вопросов**. Ведь в русском языке у слова много форм: «Гамзатова», «Гамзатову» — для программы это одно слово, только если отрезать окончание.

В помощнике я использую метод BM25 с тремя карточками: он ещё считает редкие слова более важными, и нейросеть отвечает быстрее.

Слайд 9. Эксперимент 2: три режима · 30 секунд

Теперь главный эксперимент. Я задала одной и той же нейросети все 50 вопросов в трёх режимах. Получилось 150 ответов.

Просто вопрос, как обычному чат-боту: верно только **1 из 45** обычных вопросов, остальные 44 ответа выдуманы.

Я разрешила сказать «не знаю»: она на все 45 так и ответила. Выдумок нет, но и правильных ответов нет.

С моей библиотекой — 35 из 45, то есть 78%.

Слайд 10. Нейросеть «знает», что не знает · 30 секунд

Это моё главное наблюдение. Когда я просто спрашивала, нейросеть ни разу не сказала «не знаю». А когда разрешила, сказала так на все вопросы. Получается, она как будто «знает», что не знает, но без разрешения всё равно сочиняет.

На ловушку «Какую оперу Гамзатов написал вместе с Чайковским?» она ответила «Борис Годунов», хотя Чайковский умер за 30 лет до рождения Гамзатова.

Слайд 11. Почему есть ошибки · 20 секунд

С библиотекой осталось 9 ошибок, я разобрала каждую. В 4 случаях карточка была найдена, но нейросеть прочитала её неправильно, например перепутала переводчиков Гребнева и Козловского. В 5 случаях поиск не нашёл нужную карточку. Значит, улучшать нужно и поиск, и нейросеть.

Слайд 12. Помощник в работе · 50 секунд вместе с ожиданием

[Открыть помощника в браузере. Если не запускается — остаться на слайде и рассказать по таблице.]

Покажу, как это работает. Сначала выключаю библиотеку.

[Выключить «Подглядывать в библиотеку». Спросить: «Когда родился Расул Гамзатов?»]

Нейросеть отвечает: «18 апреля 1872 года». Это выдумка.

[Включить библиотеку и задать тот же вопрос.]

Пока она читает карточки, это занимает около 20 секунд. **[Подождать ответ.]** Вот: «8 сентября 1923 года», и ниже ссылки на статьи. Нейросеть та же самая, разница только в библиотеке.

Слайд 13. Что я выяснила · 30 секунд

Итак, что я выяснила.

Первое: маленькая нейросеть почти ничего не знает о Гамзатове, но не признаётся в этом.

Второе: если разрешить ей сказать «не знаю», выдумки исчезают, но и правильных ответов нет.

Третье: для русского языка важно приводить слова к основе.

Четвёртое: ошибки с библиотекой бывают из-за поиска и из-за нейросети.

И главное: с библиотекой верных ответов стало 35 из 45, а без неё был только 1. **Гипотеза подтвердилась.**

Мой совет: не доверяйте чат-боту без проверки и выбирайте системы, которые показывают источник.

Слайд 14. Что дальше · 15 секунд

Дальше я хочу добавить больше источников — учебник и материалы музея, сделать такого же помощника по другим поэтам Дагестана и проверить его на уроке литературы.

Спасибо за внимание! Я готова ответить на ваши вопросы.

Вопросы для живой демонстрации

> Эти вопросы проверены на модели qwen2.5:1.5b. Ответы всегда одинаковые, потому что у нейросети отключена случайность (temperature = 0). Без библиотеки нейросеть ошибается во всех восьми, с библиотекой отвечает верно на все восемь. Не берите другие вопросы, не проверив их заранее: маленькая нейросеть ошибается и с библиотекой примерно в 2 случаях из 10.

Вопрос	Без библиотеки	С библиотекой
Когда родился Расул Гамзатов?	18 апреля 1872 года □	8 сентября 1923 года □

Вопрос	Без библиотеки	С библиотекой
Кто был режиссёром фильма «Горянка» 1975 года?	Виктор Степанов □	Ирина Поплавская □
Кто написал музыку к песне «Журавли»?	Михаил Глинка □	Ян Френкель □
Кто перевёл книгу «Мой Дагестан» на русский язык?	Абдулла Абдуллин □	Владимир Солоухин □
В каком институте в Москве учился Расул Гамзатов?	в МГУ □	Литературный институт им. Горького □
За какую книгу Расул Гамзатов получил Ленинскую премию?	«Мария и Мария» □	«Высокие звёзды» □
Какой номер у астероида, названного в честь Расула Гамзатова?	18621 □	7509 □
Посещение какого японского города навеяло Гамзатову тему журавлей?	«посещение Японии» □	Хиросима □

Перед защитой:

1. Запустить Ollama и сайт (`streamlit run app.py`) заранее, минут за 10. Первый ответ самый долгий, пока нейросеть загружается.
2. Задать один вопрос для «разогрева».
3. На сайте переключатель «Разрешить ответ „Я не знаю“» должен быть **выключен**. Если его включить, нейросеть без библиотеки честно ответит «Я не знаю», а не выдумает ответ.
4. Прочитать текст вслух с секундомером хотя бы два раза. Если выходит больше 6 минут 30 секунд, сократить слайд 8.