Текст выступления на защите (6–7 минут)

Тема: **«Цифровой помощник по творчеству Расула Гамзатова: может ли нейросеть отвечать на вопросы без выдумок?»**

> Подсказки в квадратных скобках — **[Слайд N]**, **[Показать]** — читать вслух не нужно.
> Говорить спокойно, не торопиться. Примерное время указано у каждой части.

---

1. Приветствие и тема (≈ 30 секунд)

[Слайд 1 — название работы]

Здравствуйте, уважаемые члены жюри! Меня зовут [имя и фамилия], я ученица 9 класса [школа]. Моя работа называется «Цифровой помощник по творчеству Расула Гамзатова: может ли нейросеть отвечать на вопросы без выдумок?».

2. Актуальность и проблема (≈ 1 минута)

[Слайд 2 — проблема]

Сегодня многие школьники делают домашние задания с помощью нейросетей. Они спрашивают у чат-бота, когда родился писатель или кто перевёл стихотворение. Нейросеть всегда отвечает уверенно и гладко. Но правильно ли?

У нейросетей есть известная проблема — **галлюцинации**. Это когда нейросеть придумывает ответ, который звучит правдоподобно, но на самом деле неверен.

[Слайд 3 — примеры выдумок]

Я проверила это сама. Я спросила нейросеть, кто перевёл «Журавли» на русский язык, и она уверенно ответила: Пушкин. Пушкин умер почти за сто лет до рождения Гамзатова. Героиню «Горянки» она назвала Айгуль, а похороненным Гамзатова — в Казани. Все ответы звучат уверенно, и все неверные.

Для дагестанской литературы эта проблема особенно важна. О Расуле Гамзатове в интернете написано намного меньше, чем, например, о Пушкине. Значит, нейросеть «прочитала» о нём мало и ошибается чаще.

3. Гипотеза, цель и задачи (≈ 40 секунд)

[Слайд 4 — гипотеза и цель]

Гипотеза моей работы: небольшая нейросеть без источников плохо отвечает на вопросы о Гамзатове. Но если дать ей возможность заглянуть в библиотеку проверенных текстов, доля верных ответов сильно вырастет.

Цель: проверить, насколько точно нейросеть отвечает на вопросы о Расуле Гамзатове, и помогает ли ей подход, который называется **RAG**.

Задачи:

1. Разобраться, почему нейросети выдумывают.
2. Собрать библиотеку текстов о Гамзатове.
3. Написать программу-помощника на языке Python.
4. Сравнить способы поиска нужного текста.
5. Сравнить ответы нейросети с библиотекой и без неё.

4. Что такое RAG (≈ 50 секунд)

[Слайд 5 — схема RAG: вопрос → библиотекарь → карточки → рассказчик → ответ]

RAG — это сокращение от английских слов «генерация, дополненная поиском». Проще всего объяснить так: это **экзамен с открытой книгой**.

Обычная нейросеть отвечает «по памяти», как ученик без учебника. А в моей системе работают два помощника:

- **Библиотекарь.** Он получает вопрос и находит в библиотеке три самых подходящих кусочка текста. Я называю их «карточками».
- **Рассказчик.** Это нейросеть. Она получает вопрос вместе с карточками и отвечает, опираясь **только на них**. Если ответа в карточках нет, она должна сказать: «В моей библиотеке нет ответа».

5. Как я делала проект (≈ 1 минута)

[Слайд 6 — этапы работы]

Первый шаг — сбор данных. Я написала программу-парсер. Она скачала 20 статей из Википедии и Викицитатника: о самом Гамзатове, его отце Гамзате Цадасе, о «Журавлях», «Горянке», «Моём Дагестане», о переводчиках Гребневе и Козловском. Я выбрала эти сайты, потому что у

них свободная лицензия, и тексты можно законно использовать. Всего получилось около 150 тысяч символов — это примерно 80 страниц книги.

Сначала я брала текст упрощённым способом, но оказалось, что при этом теряются списки, например список произведений поэта. Поэтому я переписала парсер.

Второй шаг — нарезка. Программа разрезала тексты на **303 карточки** примерно по 500 символов. Каждая карточка помнит, из какой статьи она взята. Поэтому помощник всегда показывает источник ответа.

Третий шаг — сама система. Нейросеть работает прямо на ноутбуке, без интернета, через бесплатную программу Ollama. Я использовала небольшую открытую модель Qwen: она занимает около 1 гигабайта и работает на обычном ноутбуке с 8 гигабайтами памяти.

6. Эксперименты и результаты (≈ 1 минута 40 секунд)

[Слайд 7 — набор вопросов]

Чтобы проверить гипотезу, я составила **50 вопросов** с правильными ответами по пяти темам: биография, награды, «Журавли», произведения и память о поэте. Пять из них — **вопросы-ловушки**, например: «За какой роман Гамзатов получил Нобелевскую премию?». Он её не получал, и правильный ответ — «нет» или «не знаю».

Ответы программа проверяла автоматически: ответ считался верным, если в нём есть ключевое слово, например «1923» или «Гребнев».

[Слайд 8 — график поиска]

Эксперимент 1 — поиск. Я сравнила три способа поиска карточек:

1. простое совпадение слов;
2. совпадение основ слов — это когда «Гамзатова» и «Гамзатову» считаются одним словом;
3. метод BM25, который учитывает ещё и то, что редкие слова, например «Хиросима», важнее частых.

Лучше всего сработало приведение слов к основе: при пяти карточках ответ находится для **96% вопросов**, а при простом совпадении слов — для 89%. Это потому, что в русском языке у слова много форм. В систему я выбрала BM25 с тремя карточками: он находит ответ в 89% случаев и при этом нейросеть отвечает быстрее.

[Слайд 9 — одна нейросеть, три режима]

Эксперимент 2 — ответы нейросети. Я задала одной и той же нейросети все 50 вопросов в трёх режимах. Всего 150 ответов.

1. **Просто вопрос**, как обычному чат-боту: верно только **1 из 45**, остальные 44 ответа выдуманы.
2. **Я разрешила сказать «не знаю»**: она на все 45 вопросов ответила «не знаю». Выдумок нет, но и правильных ответов нет.
3. **С моей библиотекой**: **35 из 45, то есть 78%**.

[Слайд 10 — наблюдение: нейросеть «знает», что не знает]

Отсюда моё главное наблюдение. Когда я просто спрашивала, нейросеть ни разу не сказала «не знаю». А когда разрешила, она сказала так на все вопросы. Получается, она как будто «знает», что не знает, но без разрешения всё равно сочиняет. На ловушку «Какую оперу Гамзатов написал вместе с Чайковским?» она ответила «Борис Годунов», хотя Чайковский умер за 30 лет до рождения Гамзатова. Честность зависит от того, как задать вопрос, но правильный ответ появляется только с источниками.

[Слайд 11 — разбор ошибок]

С библиотекой нейросеть ошиблась в 9 вопросах. Я разобрала каждую ошибку. В 4 случаях нужная карточка **была найдена**, но маленькая нейросеть неправильно её прочитала. Например, перепутала двух переводчиков, Гребнева и Козловского, которые упоминаются в одном тексте. В 5 случаях поиск не нашёл нужную карточку. Значит, улучшать нужно и поиск, и нейросеть.

7. Демонстрация (≈ 40 секунд)

[Слайд 12 — помощник в работе. Показать — открыть помощника в браузере]

Сейчас я покажу, как работает помощник. Сначала выключу библиотеку — нейросеть будет отвечать сама, как обычный чат-бот.

[Выключить переключатель «Подглядывать в библиотеку». Спросить: «Когда родился Расул Гамзатов?»]

Нейросеть уверенно отвечает: «18 апреля 1872 года». Это выдумка.

[Включить переключатель обратно, задать тот же вопрос]

А с библиотекой: «8 сентября 1923 года» — и ссылки на статьи, откуда взят ответ. Нейросеть та же самая, разница только в библиотеке.

> Если демонстрация не запустилась — спокойно сказать: «Пока программа загружается, покажу скриншот» — и показать слайд 12 с таблицей.

8. Выводы (≈ 40 секунд)

[Слайд 13 — что я выяснила]

Итак, что я выяснила:

1. Маленькая нейросеть почти ничего не знает о Гамзатове, но **не признаётся** в этом: 44 выдумки из 45 ответов.
2. Если разрешить ей сказать «не знаю», выдумки исчезают, но и **правильных ответов нет**.
3. Для русского языка важно приводить слова к основе: тогда поиск находит ответ в **96%** случаев.
4. Ошибки с библиотекой бывают двух видов: поиск **не нашёл** карточку или нейросеть **неправильно прочитала** найденную.
5. С библиотекой верных ответов стало **35 из 45**, а без неё был только **1**. **Гипотеза подтвердилась.**

Мой совет школьникам: не доверяйте ответам чат-бота без проверки и пользуйтесь системами, которые показывают, откуда взят ответ.

[Слайд 14 — перспективы]

В будущем я хочу добавить в библиотеку школьный учебник по литературе Дагестана, материалы музея Гамзатова и тексты на аварском языке.

Спасибо за внимание! Я готова ответить на ваши вопросы.

Возможные вопросы жюри и ответы

> Отвечать коротко: 2–4 предложения. Если не знаешь ответа — честно сказать: «Я этого не проверяла, но думаю, что…». Это лучше, чем выдумывать (как нейросеть).

О проекте в целом

1. Почему вы выбрали именно Расула Гамзатова? Это гордость Дагестана, его «Журавли» знает весь мир, а в 2023 году отмечали его 100-летие. К тому же о нём в интернете меньше информации, чем о Пушкине, поэтому нейросети знают о нём мало и ошибаются чаще. Это делает проверку интереснее.

2. Чем ваш помощник лучше обычного ChatGPT или «Алисы»? Мой помощник показывает источник каждого ответа, поэтому его можно проверить. Он отвечает только по проверенным текстам и работает без интернета на обычном ноутбуке. А большие чат-боты не всегда говорят, откуда они взяли ответ.

3. Где это можно применить? На уроках литературы, в неделю «Белых журавлей», при подготовке к Гамзатовским чтениям, в школьной библиотеке. Ещё в библиотеку можно положить любые другие тексты, например учебник или материалы школьного музея, и получится помощник по другой теме.

4. Что вы сделали сами? Я составила список источников и 50 вопросов с ответами, написала программы для сбора и нарезки текстов, поиска и экспериментов, провела эксперименты и разобрала ошибки нейросети. Саму нейросеть Qwen я не создавала, это готовая открытая модель.

О нейросетях и RAG

5. Что такое галлюцинация нейросети? Это ответ, который звучит правдоподобно, но не соответствует действительности. Нейросеть обучена писать гладкий текст, а не проверенный. Если она мало знает о теме, она может просто сочинить «похожий на правду» ответ.

6. Что такое RAG простыми словами? Это экзамен с открытой книгой. Сначала программа ищет в библиотеке подходящие кусочки текста, а потом нейросеть отвечает, опираясь только на них.

7. Почему вы использовали маленькую модель, а не большую? Она бесплатная и работает на обычном ноутбуке с 8 гигабайтами памяти без интернета, это может себе позволить любая школа. Кроме того, на маленькой модели лучше видно, насколько библиотека помогает.

8. Что такое Ollama? Это бесплатная программа, которая позволяет запускать нейросети прямо на своём компьютере. Моя программа отправляет ей вопрос и получает ответ.

9. Что такое temperature = 0? Это настройка, которая отключает случайность у нейросети. Тогда на один и тот же вопрос она всегда отвечает одинаково, и эксперимент можно повторить с тем же результатом.

О данных

10. Откуда вы взяли тексты? Это законно? Из Википедии и Викицитатника. У них свободная лицензия CC BY-SA, поэтому тексты можно законно использовать, если указать источник. Сами стихи Гамзатова защищены авторским правом, поэтому я их не брала целиком.

11. Можно ли доверять Википедии? Не всегда полностью, но это открытый и проверяемый источник со ссылками на литературу. В моей работе важно другое: нейросеть отвечает по тому, что есть в библиотеке. Если положить туда учебник или книги, точность источника станет выше.

12. Что такое парсер? Это программа, которая скачивает страницу сайта и «вытаскивает» из неё нужный текст: абзацы, списки, таблицы. Служебные части, например ссылки и примечания, она выбрасывает.

13. Зачем резать тексты на карточки? Почему не дать нейросети всё сразу? Нейросеть не может прочитать сразу 150 тысяч символов: у неё ограничен объём памяти, и она работала бы очень долго. Поэтому мы находим только 3 самые подходящие карточки и даём ей их.

Об экспериментах

14. Сколько вопросов было в эксперименте? Все 50: 45 обычных и 5 ловушек. Каждый вопрос я задала три раза: просто так, с разрешением сказать «не знаю» и с библиотекой. Всего 150 ответов.

15. Почему без библиотеки только 1 правильный ответ? Маленькая нейросеть почти ничего не знает о Гамзатове: о нём мало текстов в интернете, на которых она училась. Но она не признаётся, а уверенно выдумывает. Это и есть главная опасность.

16. А если разрешить нейросети сказать «не знаю»? Тогда она на все 45 вопросов честно ответила «не знаю». Выдумок нет, но и правильных ответов тоже нет. На сайте это можно показать переключателем «Разрешить ответ „Я не знаю“».

17. Как нейросеть справилась с ловушками? Без библиотеки она попалась на все 5 ловушек и выдумала ответ. С библиотекой распознала 3 из 5, на остальные ответила «в моей библиотеке нет ответа» или ошиблась.

18. Почему с библиотекой всё равно 9 ошибок? Я разобрала каждую. В 4 случаях поиск нашёл правильную карточку, но маленькая нейросеть неправильно её прочитала: например, в тексте про «Журавли» есть и Гребнев, и Козловский, и она назвала не того. В 5 случаях поиск не нашёл нужную карточку. Поэтому помощник всегда показывает источник, чтобы ответ можно было проверить.

19. То, что RAG помогает, известно с 2020 года. Что нового вы выяснили? Я проверила это на теме, где нейросети знают особенно мало, — на дагестанской литературе, и посчитала, насколько велика разница: 1 верный ответ против 35. Ещё я заметила, что нейросеть сама не признаётся, что не знает, но если ей разрешить, говорит «не знаю» на все вопросы. И я разобрала, откуда берутся ошибки даже с библиотекой: примерно поровну из-за поиска и из-за нейросети.

20. Как проверялись ответы? Не мог ли автомат ошибиться? Ответ считался верным, если в нём есть ключевое слово из правильного ответа. Автомат может ошибиться, например, если нейросеть написала имя с опечаткой. Поэтому все ответы нейросети сохранены в таблице, и каждый можно проверить вручную.

21. Почему выбрали BM25, если поиск по основам слов дал 96%? 96% получилось при 5 карточках. Но чем больше карточек, тем дольше отвечает нейросеть на слабом компьютере. При 3 карточках поиск по основам и BM25 дают одинаковые 89%. BM25 я выбрала, потому что он ещё учитывает редкость слов и длину карточки, то есть более надёжен.

22. Что такое стемминг (основа слова)? Это когда у слова отрезается окончание: «журавлях», «журавли», «журавлей» превращаются в «журавл». Тогда программа понимает, что это одно и то же слово.

О развитии

23. Как улучшить точность? Взять более мощную модель, добавить в библиотеку больше источников, например учебник и книги, и попробовать поиск по смыслу с помощью эмбеддингов.

24. Вы используете эмбеддинги? Нет. Мой поиск работает по словам: BM25 считает, сколько слов вопроса есть в карточке, и придаёт редким словам больше веса. Эмбеддинги — это когда текст превращают в набор чисел, и похожие по смыслу тексты получают похожие числа. Тогда находятся карточки даже без общих слов. Но для этого нужна ещё одна нейросеть, это медленнее на слабом ноутбуке, и сложнее понять, почему

нашлась карточка. Поэтому я выбрала BM25, а эмбеддинги — следующий шаг.

25. Почему нет стихов на аварском языке? Для аварского языка почти нет готовых инструментов, и маленькие нейросети его плохо понимают. Это одно из моих направлений на будущее.

26. Сколько времени занял проект и что было самым трудным? **[Ответить честно про себя.]** Например: самым трудным было составить 50 вопросов с правильными ответами и проверить их, а ещё ждать, пока нейросеть ответит на слабом ноутбуке.