Возможные вопросы жюри и ответы

Текст самого выступления — в файле «1_Текст_выступления».

Отвечать коротко: 2–4 предложения. Если не знаешь ответа — честно сказать: «Я этого не проверяла, но думаю, что…». Это лучше, чем выдумывать (как нейросеть).

О проекте в целом

1. Почему вы выбрали именно Расула Гамзатова? Это гордость Дагестана, его «Журавли» знает весь мир, а в 2023 году отмечали его 100-летие. К тому же о нём в интернете меньше информации, чем о Пушкине, поэтому нейросети знают о нём мало и ошибаются чаще. Это делает проверку интереснее.

2. Чем ваш помощник лучше обычного ChatGPT или «Алисы»? Мой помощник показывает источник каждого ответа, поэтому его можно проверить. Он отвечает только по проверенным текстам и работает без интернета на обычном ноутбуке. А большие чат-боты не всегда говорят, откуда они взяли ответ.

3. Где это можно применить? На уроках литературы, в неделю «Белых журавлей», при подготовке к Гамзатовским чтениям, в школьной библиотеке. Ещё в библиотеку можно положить любые другие тексты, например учебник или материалы школьного музея, и получится помощник по другой теме.

4. Что вы сделали сами? Я составила список источников и 50 вопросов с ответами, написала программы для сбора и нарезки текстов, поиска и экспериментов, провела эксперименты и разобрала ошибки нейросети. Саму нейросеть Qwen я не создавала, это готовая открытая модель.

О нейросетях и RAG

5. Что такое галлюцинация нейросети? Это ответ, который звучит правдоподобно, но не соответствует действительности. Нейросеть обучена писать гладкий текст, а не проверенный. Если она мало знает о теме, она может просто сочинить «похожий на правду» ответ.

6. Что такое RAG простыми словами? Это экзамен с открытой книгой. Сначала программа ищет в библиотеке подходящие кусочки текста, а потом нейросеть отвечает, опираясь только на них.

7. Почему вы использовали маленькую модель, а не большую? Она бесплатная и работает на обычном ноутбуке с 8 гигабайтами памяти без интернета, это может себе позволить любая школа. Кроме того, на маленькой модели лучше видно, насколько библиотека помогает.

8. Что такое Ollama? Это бесплатная программа, которая позволяет запускать нейросети прямо на своём компьютере. Моя программа отправляет ей вопрос и получает ответ.

9. Что такое temperature = 0? Это настройка, которая отключает случайность у нейросети. Тогда на один и тот же вопрос она всегда отвечает одинаково, и эксперимент можно повторить с тем же результатом.

О данных

10. Откуда вы взяли тексты? Это законно? Из Википедии и Викицитатника. У них свободная лицензия CC BY-SA, поэтому тексты можно законно использовать, если указать источник. Сами стихи Гамзатова защищены авторским правом, поэтому я их не брала целиком.

11. Можно ли доверять Википедии? Не всегда полностью, но это открытый и проверяемый источник со ссылками на литературу. В моей работе важно другое: нейросеть отвечает по тому, что есть в библиотеке. Если положить туда учебник или книги, точность источника станет выше.

12. Что такое парсер? Это программа, которая скачивает страницу сайта и «вытаскивает» из неё нужный текст: абзацы, списки, таблицы. Служебные части, например ссылки и примечания, она выбрасывает.

13. Зачем резать тексты на карточки? Почему не дать нейросети всё сразу? Нейросеть не может прочитать сразу 150 тысяч символов: у неё ограничен объём памяти, и она работала бы очень долго. Поэтому мы находим только 3 самые подходящие карточки и даём ей их.

Об экспериментах

14. Сколько вопросов было в эксперименте? Все 50: 45 обычных и 5 ловушек. Каждый вопрос я задала три раза: просто так, с разрешением сказать «не знаю» и с библиотекой. Всего 150 ответов.

15. Почему без библиотеки только 1 правильный ответ? Маленькая нейросеть почти ничего не знает о Гамзатове: о нём мало текстов в интернете, на которых она училась. Но она не признаётся, а уверенно выдумывает. Это и есть главная опасность.

16. А если разрешить нейросети сказать «не знаю»? Тогда она на все 45 вопросов честно ответила «не знаю». Выдумок нет, но и правильных ответов тоже нет. На сайте это можно показать переключателем «Разрешить ответ „Я не знаю“».

17. Как нейросеть справилась с ловушками? Без библиотеки она попалась на все 5 ловушек и выдумала ответ. С библиотекой распознала 3 из 5, на остальные ответила «в моей библиотеке нет ответа» или ошиблась.

18. Почему с библиотекой всё равно 9 ошибок? Я разобрала каждую. В 4 случаях поиск нашёл правильную карточку, но маленькая нейросеть неправильно её прочитала: например, в тексте про «Журавли» есть и Гребнев, и Козловский, и она назвала не того. В 5 случаях поиск не нашёл нужную карточку. Поэтому

помощник всегда показывает источник, чтобы ответ можно было проверить.

19. То, что RAG помогает, известно с 2020 года. Что нового вы выяснили? Я проверила это на теме, где нейросети знают особенно мало, — на дагестанской литературе, и посчитала, насколько велика разница: 1 верный ответ против 35. Ещё я заметила, что нейросеть сама не признаётся, что не знает, но если ей разрешить, говорит «не знаю» на все вопросы. И я разобрала, откуда берутся ошибки даже с библиотекой: примерно поровну из-за поиска и из-за нейросети.

20. Как проверялись ответы? Не мог ли автомат ошибиться? Ответ считался верным, если в нём есть ключевое слово из правильного ответа. Автомат может ошибиться, например, если нейросеть написала имя с опечаткой. Поэтому все ответы нейросети сохранены в таблице, и каждый можно проверить вручную.

21. Почему выбрали BM25, если поиск по основам слов дал 96%? 96% получилось при 5 карточках. Но чем больше карточек, тем дольше отвечает нейросеть на слабом компьютере. При 3 карточках поиск по основам и BM25 дают одинаковые 89%. BM25 я выбрала, потому что он ещё учитывает редкость слов и длину карточки, то есть более надёжен.

22. Что такое стемминг (основа слова)? Это когда у слова отрезается окончание: «журавлях», «журавли», «журавлей» превращаются в «журавл». Тогда программа понимает, что это одно и то же слово.

О развитии

23. Как улучшить точность? Взять более мощную модель, добавить в библиотеку больше источников, например учебник и книги, и попробовать поиск по смыслу с помощью эмбеддингов.

24. Вы используете эмбеддинги? Нет. Мой поиск работает по словам: BM25 считает, сколько слов вопроса есть в карточке, и придаёт редким словам больше веса. Эмбеддинги — это когда текст превращают в набор чисел, и похожие по смыслу тексты получают похожие числа. Тогда находятся карточки даже без общих слов. Но для этого нужна ещё одна нейросеть, это медленнее на слабом ноутбуке, и сложнее понять, почему нашлась карточка. Поэтому я выбрала BM25, а эмбеддинги — следующий шаг.

25. Сколько времени занял проект и что было самым трудным? [Ответить честно про себя.] Например: самым трудным было составить 50 вопросов с правильными ответами и проверить их, а ещё ждать, пока нейросеть ответит на слабом ноутбуке.