Текст к презентации (6–7 минут)

Текст разбит по слайдам. Синие подсказки в квадратных скобках читать вслух не нужно.
Говорить спокойно, не торопиться. Время у каждого слайда примерное, всего около 7 минут.

Слайд 1. Название работы · 15 секунд

Здравствуйте, уважаемые члены жюри! Меня зовут [имя и фамилия], я учусь в 9 классе. Моя работа называется «Цифровой помощник по творчеству Расула Гамзатова: может ли нейросеть отвечать на вопросы без выдумок?».

Слайд 2. Проблема · 35 секунд

Сегодня многие школьники делают домашние задания с помощью нейросетей. Они спрашивают у чат-бота, когда родился писатель или кто перевёл стихотворение. Нейросеть всегда отвечает уверенно. Но правильно ли?

У нейросетей есть известная проблема — **галлюцинации**. Это когда нейросеть придумывает ответ, который звучит правдоподобно, но на самом деле неверен.

Для дагестанской литературы это особенно важно. О Расуле Гамзатове в интернете написано намного меньше, чем, например, о Пушкине. Значит, нейросеть знает о нём меньше и ошибается чаще.

Слайд 3. Что отвечает нейросеть · 25 секунд

Я проверила это сама. Я спросила нейросеть, кто перевёл «Журавли» на русский язык, и она уверенно ответила: Пушкин. Пушкин умер почти за сто лет до рождения Гамзатова. Героиню «Горянки» она назвала Айгуль, а похороненным Гамзатова — в Казани. Все ответы звучат уверенно, и все неверные.

Слайд 4. Гипотеза, цель и задачи · 35 секунд

Моя **гипотеза**: небольшая нейросеть без источников плохо отвечает на вопросы о Гамзатове. Но если дать ей библиотеку проверенных текстов, доля верных ответов сильно вырастет.

Цель работы — проверить, насколько точно нейросеть отвечает о Гамзатове и помогает ли ей подход, который называется RAG.

Для этого я поставила пять задач: разобраться, почему нейросети выдумывают, собрать библиотеку, написать помощника на Python, сравнить способы поиска и сравнить ответы с библиотекой и без неё.

Слайд 5. Что такое RAG · 40 секунд

RAG можно объяснить очень просто: это **экзамен с открытой книгой**. Обычная нейросеть отвечает «по памяти», как ученик без учебника.

В моей системе работают два помощника. **Библиотекарь** получает вопрос и находит три самых подходящих кусочка текста — я называю их карточками. **Рассказчик** — это нейросеть. Она читает эти карточки и отвечает.

Главное — задание, которое получает нейросеть: «Ответь, используя только эти фрагменты. Если ответа нет, скажи: „В моей библиотеке нет ответа“». Так она не может выдумывать, а пользователь видит, откуда взят ответ.

Слайд 6. Как я делала проект · 40 секунд

Работа шла в три шага.

Первый шаг — сбор. Я написала программу-парсер. Она скачала 20 статей из Википедии и Викицитатника: о самом Гамзатове, его отце, «Журавлях», «Горянке», переводчиках. У этих сайтов свободная лицензия, поэтому тексты можно законно использовать.

Второй шаг — нарезка. Программа разрезала тексты на 303 карточки. Каждая помнит, из какой статьи она взята.

Третий шаг — помощник. Нейросеть Qwen работает прямо на ноутбуке, без интернета, через бесплатную программу Ollama. Она маленькая, около 1 гигабайта, и ей хватает обычного ноутбука с 8 гигабайтами памяти.

Слайд 7. Как я проверяла · 30 секунд

Чтобы проверить гипотезу, я составила **50 вопросов** с правильными ответами по пяти темам: биография, произведения, «Журавли», награды и память о поэте.

Пять вопросов — **ловушки**. Например: «За какой роман Гамзатов получил Нобелевскую премию?». Он её не получал, и правильный ответ — «нет» или «не знаю».

Ответы программа проверяла автоматически: ответ верный, если в нём есть ключевое слово, например «1923» или «Гребнев».

Слайд 8. Эксперимент 1: поиск · 40 секунд

Сначала я проверила библиотекаря: находит ли он нужную карточку. Я сравнила три способа поиска: простое совпадение слов, совпадение основ слов и метод BM25, который считает редкие слова более важными.

Лучше всего сработал поиск по основам слов: среди пяти карточек он находит ответ для **96% вопросов**. Это потому, что в русском языке у слова много форм: «Гамзатова», «Гамзатову» — для программы это одно слово только после приведения к основе.

В помощник я взяла BM25 с тремя карточками: он находит ответ в 89% случаев, а нейросеть отвечает быстрее.

Слайд 9. Эксперимент 2: три режима · 35 секунд

Теперь главный эксперимент. Я задала одной и той же нейросети все 50 вопросов в трёх режимах — всего 150 ответов.

Просто вопрос, как обычному чат-боту: верно только **1 из 45**, остальные 44 ответа выдуманы.

Я разрешила сказать «не знаю»: она на все 45 вопросов так и ответила. Выдумок нет, но и правильных ответов нет.

С моей библиотекой — 35 из 45, то есть 78%.

Слайд 10. Нейросеть «знает», что не знает · 30 секунд

Это моё главное наблюдение. Когда я просто спрашивала, нейросеть ни разу не сказала «не знаю». А когда разрешила, она сказала так на все вопросы. Получается, она как будто «знает», что не знает, но без разрешения всё равно сочиняет.

Например, на ловушку «Какую оперу Гамзатов написал вместе с Чайковским?» она ответила «Борис Годунов». А Чайковский умер за 30 лет до рождения Гамзатова.

Вывод: честность нейросети зависит от того, как задать вопрос. Но правильный ответ появляется только с источниками.

Слайд 11. Почему есть ошибки · 25 секунд

С библиотекой осталось 9 ошибок, и я разобрала каждую. В 4 случаях библиотекарь **нашёл нужную карточку**, но маленькая нейросеть прочитала её неправильно. Например, перепутала переводчиков Гребнева и Козловского, которые упоминаются в одном тексте. В 5 случаях поиск не нашёл нужную карточку.

Значит, улучшать нужно и поиск, и нейросеть. А пока помощник показывает источник, и ответ всегда можно проверить.

Слайд 12. Помощник в работе · 35 секунд

[Открыть помощника в браузере. Если не запускается — остаться на этом слайде и рассказать по таблице.]

Вот как работает помощник. Сначала я выключаю библиотеку — теперь нейросеть отвечает сама, как обычный чат-бот.

[Выключить переключатель «Подглядывать в библиотеку». Спросить: «Когда родился Расул Гамзатов?»]

Нейросеть уверенно отвечает: «18 апреля 1872 года». Это выдумка.

[Включить переключатель обратно, задать тот же вопрос.]

А теперь с библиотекой: «8 сентября 1923 года» — и ниже ссылки на статьи, откуда взят ответ. Это одна и та же нейросеть, разница только в моей библиотеке. В таблице на слайде — ещё несколько таких примеров.

Слайд 13. Что я выяснила · 35 секунд

Итак, что я выяснила.

Первое: маленькая нейросеть почти ничего не знает о Гамзатове, но не признаётся в этом — 44 выдумки из 45.

Второе: если разрешить ей сказать «не знаю», выдумки исчезают, но и правильных ответов нет.

Третье: для русского языка важно приводить слова к основе — тогда поиск находит ответ в 96% случаев.

Четвёртое: ошибки с библиотекой бывают двух видов — поиск не нашёл карточку или нейросеть неправильно её прочитала.

И главное: с библиотекой верных ответов стало 35 из 45, а без неё был только 1. **Гипотеза подтвердилась.**

Мой совет школьникам: не доверяйте чат-боту без проверки и выбирайте системы, которые показывают источник.

Слайд 14. Что дальше · 15 секунд

В будущем я хочу добавить в библиотеку школьный учебник и тексты на аварском языке и взять более мощную нейросеть.

Спасибо за внимание! Я готова ответить на ваши вопросы.

Вопросы для живой демонстрации

> Эти вопросы проверены на модели qwen2.5:1.5b. Ответы всегда одинаковые, потому что у нейросети отключена случайность (temperature = 0). Без библиотеки нейросеть ошибается во всех восьми, с библиотекой отвечает верно на все восемь. Не берите другие вопросы, не проверив их заранее: маленькая нейросеть ошибается и с библиотекой примерно в 2 случаях из 10.

Вопрос	Без библиотеки	С библиотекой
Когда родился Расул Гамзатов?	18 апреля 1872 года □	8 сентября 1923 года □
Кто был режиссёром фильма «Горянка» 1975 года?	Виктор Степанов □	Ирина Поплавская □
Кто написал музыку к песне «Журавли»?	Михаил Глинка □	Ян Френкель □
Кто перевёл книгу «Мой Дагестан» на русский язык?	Абдулла Абдуллин □	Владимир Солоухин □
В каком институте в Москве учился Расул Гамзатов?	в МГУ □	Литературный институт им. Горького □
За какую книгу Расул Гамзатов получил Ленинскую премию?	«Мария и Мария» □	«Высокие звёзды» □
Какой номер у астероида, названного в честь Расула Гамзатова?	18621 □	7509 □
Посещение какого японского города навеяло Гамзатову тему журавлей?	«посещение Японии» □	Хиросима □

Перед защитой:

1. Запустить Ollama и сайт (`streamlit run app.py`) заранее, минут за 10. Первый ответ самый долгий, пока нейросеть загружается.
2. Задать один вопрос для «разогрева».
3. На сайте переключатель «Разрешить ответ „Я не знаю“» должен быть **выключен**. Если его включить, нейросеть без библиотеки честно ответит «Я не знаю», а не выдумает ответ.